

Báo cáo training Data Analyst

Chủ đề 2: Data Warehouse

Họ và tên	:	Nguyễn Hoàng Yên
Ngày tháng	:	29/05/2026
Người hướng dẫn	:	...

1. Các loại dữ liệu bán cấu trúc	2
2. Phương pháp lưu ảnh, âm thanh dưới các hệ CSDL/Data Lake	4
3. Định nghĩa Data warehouse của Kimball và Inmon	5
1. Phương pháp Kimball	5
2. Phương pháp Inmon	6
3. Hybrid Approach	6
4. Data Vault	7
5. SCD (Slowly changing dimension)	9

1. Các loại dữ liệu bán cấu trúc

a. JSON

JSON (JavaScript Object Notation) là một kiểu định dạng dữ liệu tuân theo quy luật sử dụng các cặp key – value. Hỗ trợ các cấu trúc dữ liệu như đối tượng và mảng, thường dùng API, NoSQL,...

JSON lưu dữ liệu theo:

- object { }: Chuỗi JSON được bao lại bởi dấu ngoặc nhọn {}, dùng để nhóm các dữ liệu liên quan
- array []: Dùng để lưu nhiều phần tử

VD:

```
{  
  "subjects": ["Math", "Python", "SQL"]  
}
```

- key-value: Các key, value của JSON bắt buộc phải đặt trong dấu nháy kép {}.
Nếu trường hợp trong value có chứa dấu nháy kép " thì dùng dấu \ để đặt trước nó, ví dụ

```
{  
  "text": "JSON là \"định dạng dữ liệu\""  
}
```

VD:

```
{  
  "customer_id": 101,  
  "name": "Linh",  
  "city": "Ha Noi",  
  "orders": [  
    {  
      "product": "iPhone",  
      "price": 1000  
    },  
    {  
      "product": "AirPods",  
      "price": 200  
    }  
  ]  
}
```

b. XML

XML (Extensible Markup Language) là ngôn ngữ đánh dấu mở rộng được thiết kế để lưu trữ và truyền tải dữ liệu một cách có cấu trúc. Tác dụng chính của XML là đơn giản hóa việc chia sẻ dữ liệu giữa các nền tảng và các hệ thống được kết nối thông qua mạng Internet.

XML lưu dữ liệu theo: <tag> dữ liệu </tag> (opening tag - value - closing tag)

VD:

```
<customer>
  <customer_id>101</customer_id>
  <name>Linh</name>
  <city>Ha Noi</city>

  <orders>
    <order>
      <product>iPhone</product>
      <price>1000</price>
    </order>

    <order>
      <product>AirPods</product>
      <price>200</price>
    </order>
  </orders>
</customer>
```

→ Cùng 1 dữ liệu:

JSON

```
{
  "name": "Linh",
  "age": 19
}
```

XML

```
<person>
  <name>Linh</name>
  <age>19</age>
```

</person>

Link tham khảo:<https://topdev.vn/blog/json-la-gi/>

2. Phương pháp lưu ảnh, âm thanh dưới các hệ CSDL/Data Lake

Ảnh, âm thanh, video là dữ liệu phi cấu trúc

Trong CSDL truyền thống:

- Lưu trực tiếp:
 - + File ảnh/âm thanh được lưu trên các ổ đĩa máy chủ hoặc Cloud Storage. CSDL chỉ lưu chuỗi đường dẫn (URL) trỏ tới file đó, kèm theo các siêu dữ liệu (metadata) như kích thước, ngày tải lên.
 - + Chuyển đổi file thành chuỗi nhị phân (BLOB: Binary Large Object) hoặc mã hóa Base64 để lưu thẳng vào các cột trong bảng CSDL. Cách này làm cơ sở dữ liệu trở nên nặng và giảm hiệu năng truy vấn.

VD:

```
CREATE TABLE photos (  
  id INT,  
  image LONGBLOB  
);
```

→ Chiếm storage lớn, làm cho database cực nặng nên thực tế CSDL chỉ lưu metadata (siêu dữ liệu: kích thước, ngày tải lên) + file path

id	file_name	path
1	cat.jpg	/images/cat.jpg

- Lưu theo đặc trưng: Với các hệ thống AI/Machine Learning, dữ liệu ảnh/âm thanh thường được phân tích và lưu dưới dạng các chuỗi số Vector (Vector embeddings) để phục vụ tìm kiếm tương đồng (như nhận diện khuôn mặt)

Còn Data Lake thì lưu mọi kiểu dữ liệu (lưu raw data), nên với ảnh/audio/video, lưu trực tiếp dạng file.

3. Định nghĩa Data warehouse của Kimball và Inmon

Data mart là một phần phụ của data warehouse, được thiết kế và xây dựng đặc biệt cho một bộ phận/chức năng kinh doanh cụ thể, giúp bảo mật và hiệu suất được tách biệt.

- Data Warehouse chứa dữ liệu tổng
- Data Mart lấy phần dữ liệu liên quan để phục vụ analytics riêng

1. Phương pháp Kimball

- Sử dụng cách tiếp cận bottom-up trong thiết kế data warehouse. Theo đó, các data marts được xây dựng trước dựa trên nhu cầu nghiệp vụ (doanh nghiệp cần cái gì thì build cái đó trước).
- Dữ liệu từ nhiều nguồn sẽ được lấy thông qua quy trình ETL (Extract, Transform, Load) và đưa vào vùng staging. Sau đó, dữ liệu được load vào dimensional data warehouse model, gồm fact và dim tables.
- Mô hình cốt lõi: Star Schema

Kimball sử dụng khái niệm conformed dimensions (một dimension table được dùng chung cho nhiều fact tables/data marts để đảm bảo dữ liệu nhất quán) để đồng bộ dữ liệu giữa các fact tables và data marts, giúp đảm bảo tính nhất quán dữ liệu toàn hệ thống.

Ngoài ra, phương pháp này còn sử dụng Kimball Bus Architecture (bản kế hoạch tổng thể cho toàn bộ data warehouse) để quản lý và ưu tiên triển khai các star schema theo nhu cầu doanh nghiệp.

Ưu điểm

- Thiết kế nhanh do không cần chuẩn hóa dữ liệu (normalisation).
- Star schema dễ hiểu, dễ query và phân tích.
- Tối ưu hiệu suất truy vấn OLAP.
- Dễ triển khai theo từng phòng ban/process.
- Quản lý đơn giản, phù hợp BI và reporting.
- Data mart có thể phát triển độc lập.

Nhược điểm của Kimball

- Không tạo được “single source of truth” hoàn chỉnh (vì chia ra làm các data marts riêng).

**Single Source of Truth (SSOT) là nguyên tắc quản lý dữ liệu trong đó mọi thông tin quan trọng của tổ chức chỉ được lưu trữ tại một vị trí duy nhất.*

- Dễ xảy ra dư thừa dữ liệu do hạn chế chuẩn hóa dữ liệu.
- Khó thay đổi khi business requirements thay đổi mạnh.
- Không phù hợp cho enterprise-wide reporting phức tạp.

2. Phương pháp Inmon

- Sử dụng cách tiếp cận top-down trong xây dựng data warehouse.

- Phương pháp này xây dựng data warehouse trước bằng mô hình chuẩn hóa, giúp giảm dư thừa dữ liệu và tăng tính nhất quán.
 - Sau khi data warehouse hoàn thiện, các data mart mới được tạo riêng cho từng bộ phận như finance, sales hoặc marketing.
- Inmon tập trung vào việc xây dựng một single source of truth cho toàn doanh nghiệp.

Ưu điểm

- Dữ liệu tích hợp và nhất quán toàn doanh nghiệp.
- Dễ thích nghi khi business requirements thay đổi.
- Hỗ trợ enterprise-wide reporting tốt.
- Data quality và integrity cao hơn.


Nhược điểm

- Thiết kế phức tạp hơn do chuẩn hóa dữ liệu.
- Thời gian triển khai dài.
- Cần đội ngũ chuyên môn cao.
- ETL process phức tạp hơn.
- Query và analytics khó hơn vì nhiều bảng liên kết.

3. Hybrid Approach

Nhiều doanh nghiệp hiện nay sử dụng Hybrid Data Model, kết hợp cả Kimball và Inmon:

- + Inmon dùng để xây dựng enterprise data warehouse.
- + Kimball dùng để xây dựng data marts với star schema.



Hybrid vẫn theo flow của Inmon (Data Warehouse trước, Data Mart sau), nhưng các Data Mart được thiết kế theo Kimball với Star Schema để tối ưu BI và OLAP analytics.

Kimball phù hợp với triển khai nhanh và BI/reporting theo business process, trong khi Inmon phù hợp với enterprise-wide analytics và quản trị dữ liệu tập trung.

Link tham khảo:

[https://www-astera-com.translate.googleusercontent.com/translate/g?_x_tr_sl=en&
_x_tr_tl=vi&_x_tr_pto=tcm&_x_tr_hist=true](https://www-astera-com.translate.googleusercontent.com/translate/g?_x_tr_sl=en&_x_tr_tl=vi&_x_tr_pto=tcm&_x_tr_hist=true)

4. Data Vault

a. Khái niệm

Data Vault là phương pháp mô hình hóa data warehouse dùng để quản lý dữ liệu lớn cho BI và analytics → Cách tổ chức data warehouse theo kiểu module.

Mô hình này được Dan Linstedt phát triển vào những năm 1990 nhằm giải quyết các hạn chế của mô hình truyền thống (Star/Snowflake schema) và hỗ trợ enterprise-scale analytics (khó mở rộng khi dữ liệu tăng lên cực lớn, khó thay đổi khi cấu trúc business thay đổi, audit kém,...).

Data Vault kết hợp ưu điểm của mô hình chuẩn hóa 3NF, Star Schema và Snowflake Schema để tạo ra hệ thống linh hoạt, scalable, dễ mở rộng, lưu lịch sử dữ liệu tốt.

b. Mô hình Data Vault

Hiện nay chủ yếu sử dụng Data Vault 2.0, phiên bản cải tiến của Data Vault 1.0. Ba thành phần chính của Data Vault

1. Hubs

Hub đại diện cho các business entities cốt lõi như: Customer, Product, Sales

Hub chỉ lưu: business keys, hash keys, load information, record source,..., không lưu thông tin mô tả chi tiết.

Ví dụ:

Hub Customer

CustomerID

HashKey

LoadDate

Thành phần chính trong Hub

- Business Key: khóa nghiệp vụ thực tế như CustomerID, ProductCode.
- Hash Key: khóa được tạo bằng thuật toán hash để làm primary key.
- Load Date: thời gian dữ liệu được load vào hệ thống (metadata).
- Record Source: nguồn dữ liệu gốc.

2. Links

Link đại diện cho mối quan hệ giữa các hubs.

Ví dụ: Customer mua Product

→ Link chứa: hash keys, foreign keys, load date, record source.

Link_Order

CustomerHashKey

ProductHashKey

3. Satellites

Satellite lưu: descriptive attributes, historical data. Ví dụ thông tin khách hàng: name, address, phone number

Satellite hỗ trợ tracking changes theo thời gian bằng timestamp. Một Hub hoặc Link có thể có nhiều Satellites.

Ví dụ:

Sat_Customer

CustomerName

Address

LoadDate

4. Quan hệ giữa Hub, Link và Satellite

- Hub = business entity
- Link = relationship
- Satellite = descriptive + historical data

→ Ba thành phần này kết hợp tạo nên hệ thống data warehouse.

Ưu điểm của Data Vault

- Dễ mở rộng hệ thống.
- Hỗ trợ historical tracking rất tốt.
- Linh hoạt khi business requirements thay đổi.
- Tích hợp dữ liệu từ nhiều nguồn dễ dàng.
- Tối ưu cho Big Data và cloud architecture.

Nhược điểm của Data Vault

- Thiết kế phức tạp hơn Star Schema.
- Số lượng bảng rất lớn.

- Query analytics trực tiếp chậm hơn.
- ETL/ELT phức tạp hơn.

Khác với Star Schema và Snowflake Schema vốn tối ưu cho OLAP và reporting, Data Vault thường được dùng làm lớp lưu trữ trung gian trước khi dữ liệu được chuyển sang data marts hoặc star schema để phục vụ BI và analytics.

<https://viblo.asia/p/data-vault-xay-dung-kho-du-lieu-doanh-nghiep-enterprise-data-warehouse-edw-13VM90kdVY7>

<https://bsdinsight.com/hieu-ve-data-vault-va-data-vault-2-0/>

<https://www.altexsoft.com/blog/data-vault-architecture/>

5. SCD (Slowly changing dimension) - Kimball

a. Khái niệm

SCD (Slowly Changing Dimension) là cách xử lý khi dữ liệu trong Dimension Table bị thay đổi theo thời gian.

SCD quản lý các thay đổi chậm của dữ liệu mô tả, đảm bảo mỗi sự kiện luôn được kết nối với đúng “phiên bản” của thực thể tại thời điểm đó.

b. Các loại SCD

1. SCD Type 0:

SCD Type 0 được dành riêng cho những dữ liệu mang tính định danh gốc và không bao giờ thay đổi sau khi đã được nạp lần đầu.

VD: : ngày sinh của khách hàng hoặc mã định danh ban đầu của một thiết bị,...

→ Giúp bảo mật, ngăn chặn các lỗi logic từ hệ thống nguồn làm sai lệch những thông tin mang tính nền tảng.

2. SCD Type 1: Ghi đè

Khi dữ liệu thay đổi, giá trị mới sẽ ghi đè trực tiếp lên giá trị cũ, phù hợp cho những thông tin không có giá trị phân tích quá khứ.

VD: sửa lỗi chính tả tên khách hàng, cập nhật số điện thoại hoặc email,....

3. SCD Type 2: Giữ full history

Thay vì thay đổi dòng cũ, hệ thống tạo ra một dòng mới với một Surrogate Key (Khóa thay thế) riêng biệt.

VD: Khi một khách hàng thay đổi địa chỉ, bản ghi cũ sẽ được “đóng” lại bằng cách cập nhật end_date là ngày hôm nay, và một bản ghi mới được “mở” ra. Nhờ đó, Fact Table có thể tìm đúng phiên bản dữ liệu mô tả dựa trên thời điểm giao dịch xảy ra thông qua phép Join trên Surrogate Key.

4. SCD Type 3:

Lưu giá trị hiện tại và một giá trị ngay trước đó trong cùng một dòng bằng cách thêm cột previous_value.

→ Không làm tăng số lượng bản ghi, tuy nhiên chỉ lưu được một phiên bản lịch sử duy nhất. Nếu dữ liệu thay đổi lần thứ ba, thông tin của lần thứ nhất sẽ bị xóa bỏ. Nó thường được dùng cho các thay đổi có tính chất chu kỳ hoặc ngắn hạn.

5. SCD Type 4:

Hệ thống duy trì hai bảng: một bảng chỉ chứa dữ liệu mới nhất (giúp báo cáo BI chạy cực nhanh) và một bảng phụ lưu toàn bộ lịch sử (History table).

Link tham khảo:

<https://indaacademy.vn/dwh/slowly-changing-dimension-scd/>